

دانشگاه صنعتی خواجه نصیرالدین طوسی

دانشگاه صنعتی خواجه نصیرالدین طوسی
دانشکده مهندسی کامپیوتر

یادگیری تقویتی

پروژه پایانی

نگارش

ارشیا اکبری آل آقا

استاد درس

دکتر خواسته

۱۱ مرداد ۱۴۰۵

فهرست مطالب

۲	۱ تعریف مسئله
۲	۱.۱ ویژگی پویای انتخاب‌شده: دروازه‌ی دوره‌ای
۲	۲ طراحی محیط
۲	۱.۲ تولید نقشه و اعتبارسنجی
۳	۲.۲ صورت‌بندی MDP
۴	۳.۲ طراحی پاداش (دو نسخه)
۵	۴.۲ راستی‌آزمایی
۶	۳ Value Iteration
۹	۴ الگوریتم Q-Learning
۹	۱.۴ زمان‌بندی‌های کاهش ϵ
۱۰	۲.۴ پاداش اسپارس در برابر پاداش شکل‌دهی‌شده
۱۲	۵ الگوریتم SARSA با Eligibility Traces
۱۲	۱.۵ جاروب λ
۱۳	۲.۵ رفتار δ و E در طول یک اپیزود
۱۴	۶ مقایسه‌ی سه الگوریتم
۱۸	۷ یادگیری انتقالی (با Q-Learning)
۱۸	۱.۷ محیط‌های هدف
۱۸	۲.۷ سناریوها و نتایج
۲۳	۳.۷ یک مورد انتقال منفی، از آغاز تا پایان
۲۵	۸ رابط گرافیکی MazeMario
۲۸	۹ جمع‌بندی مقایسه
۲۹	۱۰ پاسخ به پرسش‌های تحلیلی
۳۰	۱۱ بازتولیدپذیری
۳۱	۱۲ پیاده‌سازی‌های فیچرهای دیگر

فهرست جداول

۱	صورت‌بندی رسمی مسئله به‌شکل یک فرایند تصمیم‌گیری مارکوف	۳
۲	اثر ضریب تنزیل بر همگرایی و کیفیت سیاست	۶
۳	مقایسه‌ی زمان‌بندی خطی و نمایی کاهش ε (هر کدام روی 3 بذری)	۹
۴	اثر شکل‌دهی پاداش بر سرعت یادگیری (هر کدام روی 3 بذری)	۱۰
۵	اثر λ بر سرعت و پایداری یادگیری	۱۲
۶	مقایسه‌ی کمی سه الگوریتم روی نقشه‌ی مبدأ	۱۴
۷	مشخصات دو محیط هدف انتقال	۱۸
۸	نتایج سناریوهای انتقال روی هر دو هدف	۱۸
۹	تحول مقادیر Q در حالت $(12,12)$ طی آموزش روی هدف متفاوت	۲۳
۱۰	تناظر کنترل‌های خواسته‌شده با عناصر رابط گرافیکی	۲۶
۱۱	جمع‌بندی کیفی و کمی سه الگوریتم	۲۸
۱۲	چهار شاخه‌ی پیاده‌سازی و نتیجه‌ی شاخص هر یک	۳۱

فهرست تصاویر

۱	منحنی‌های همگرایی Value Iteration برای سه مقدار γ	۶
۲	نقشه‌ی حرارتی تابع مقدار (بیشینه روی فازهای دروازه) در $\gamma = 0.95$	۷
۳	سیاست بهینه به تفکیک فاز دروازه در $\gamma = 0.95$	۸
۴	مقایسه‌ی زمان‌بندی‌های کاهش ε در Q-Learning	۱۰
۵	اثر شکل‌دهی پاداش بر منحنی‌های یادگیری Q-Learning	۱۰
۶	نقشه‌ی بازدید حالت‌ها در Q-Learning (مقیاس لگاریتمی)	۱۱
۷	جاروب مقادیر λ در الگوریتم SARSA	۱۲
۸	خطای δ Temporal Difference و E Eligibility Traces در اپیزود 4900	۱۳
۹	منحنی‌های یادگیری دو روش بدون مدل	۱۴
۱۰	نقشه‌ی توافق و اختلاف Q-Learning با Value Iteration	۱۵
۱۱	نقشه‌ی توافق و اختلاف SARSA(0.7) با Value Iteration	۱۵
۱۲	مسیرهای حریصانه‌ی نهایی هر سه الگوریتم زیر جریان لغزش یکسان	۱۶
۱۳	منحنی‌های سناریوهای انتقال روی هدف مشابه	۱۹
۱۴	مقایسه‌ی جدول Q پیش و پس از انتقال روی هدف مشابه	۲۰
۱۵	منحنی‌های سناریوهای انتقال روی هدف متفاوت	۲۱
۱۶	مقایسه‌ی جدول Q پیش و پس از انتقال روی هدف متفاوت	۲۲
۱۷	جاروب β روی هدف متفاوت	۲۳
۱۸	صفحه‌ی عنوان و منوی MazeMario	۲۵
۱۹	اجرای بازی همراه با پوشش نمایش سیاست	۲۶
۲۰	صفحه‌ی پیروزی MazeMario	۲۷

چکیده

این گزارش، طراحی، پیاده‌سازی و تحلیل یک محیط هزارتوی پویا را ارائه می‌کند که به‌صورت یک فرایند تصمیم‌گیری مارکوف (MDP) مدل شده و با سه الگوریتم - Value Iteration، Q-Learning و SARSA با Eligibility Traces - حل و بررسی شده است؛ در ادامه یک مطالعه‌ی یادگیری انتقالی و یک رابط کاربری گرافیکی تعاملی به سبک بازی نیز ارائه می‌شود. تمام اعداد این گزارش به‌وسیله‌ی کد ثبت‌شده در مخزن و از روی پیکربندی ثبت‌شده (experiments/configs/default.json) و داده‌های خام (results/raw_data/) تولید شده‌اند؛ فایل README فرمان‌های دقیق بازتولید کل مجموعه‌ی خروجی‌ها را در بخش بازتولید نتایج ارائه می‌دهد.

۱ تعریف مسئله

مطابق مشخصات پروژه، بذر پایه و اندازه‌ی هزار تو از شماره دانشجویی استخراج می‌شوند:

```
student_id = "40424624"
base_seed = int(student_id[-2]) # = 2
maze_size = 15 + (base_seed % 4) # = 17 -> 17x17
```

۱.۱ ویژگی پویای انتخاب‌شده: دروازه‌ی دوره‌ای

یک خانه‌ی دروازه با دوره‌ی تناوب 6 تغییر وضعیت می‌دهد: در فازهای {0, 1, 2} باز و در فازهای {3, 4, 5} بسته است، و فاز در هر گام زمانی، چه عامل حرکت کند و چه نکند، یک واحد جلو می‌رود. ورود به دروازه‌ی بسته مانند برخورد با دیوار رفتار می‌کند (عامل در جای خود می‌ماند و پاداش -2 می‌گیرد).

دروازه به این دلیل بر گزینه‌های دیگر ترجیح داده شد که کوچک‌ترین گسترش فضای حالت ($\times 6$) است که همچنان برنامه‌ریزی زمانی واقعی را الزامی می‌کند: عامل باید درباره‌ی زمان رسیدن خود استدلال کند، نه فقط درباره‌ی مسیر رفتن (اثبات تجربی در بخش ۴). گزینه‌ی انرژی محدود، فضای حالت را حدود 100 برابر می‌کند و عملاً سقف گام‌های موردنیاز را تکرار می‌کند؛ خانه‌های لغزنده و دروازه‌های انتقال هیچ گسترشی در فضای حالت لازم ندارند و بنابراین ماده‌ی خامی برای تحلیل خاصیت مارکوف فراهم نمی‌کنند؛ و مانع متحرک عملاً معادل دروازه است اما با حالت‌های بیشتر و منطق برخورد پیچیده‌تر.

۲ طراحی محیط

۱.۲ تولید نقشه و اعتبارسنجی

نقشه به صورت بازتولیدپذیر از بذر 2 ساخته می‌شود (environments/generator.py): از 289 خانه، 56 خانه دیوار هستند (19.4%؛ حداقل خواسته شده 15%) و 6 خانه‌ی جریمه وجود دارد (حداقل خواسته شده 5) در مختصات (3,1)، (3,6)، (5,16)، (9,8)، (12,11) و (15,0). نقطه‌ی شروع (0,1)، کلید (12,10)، درِ قفل (14,13)، هدف (16,16) و دروازه (14,12) است:

.S.###.....###	S start	K key	D locked door
.####.##.....	G goal	T gate	P penalty (pit)
.....#.....	# wall	.	floor
.P.##.P#.....			
...##..#...###...			
....#.####.....P			
.....#.....			
..#...#.....			
..#..#.....			
#.#..#..P.....			
#.#.....			

```

.....####.
.....#...KP.....
.....#.....#####
.....#.....TD...
P....##.....#...
.....###.....#...G

```

دو تصمیم ساختاری برای همه‌ی تحلیل‌های بعدی اهمیت دارند:

- هدف در محفظه‌ای دیواردار قرار دارد که تنها ورودی آن در قفل است، بنابراین ترتیب مأموریت (شروع ← کلید ← در ← هدف) به‌جای طراحی پاداش، با هندسه‌ی نقشه تحمیل می‌شود.

- دروازه دقیقاً روی تنها خانه‌ی مسیر پیش از در قرار گرفته است، پس هر اپیزود موفق ناگزیر با آن تعامل می‌کند. (در نسخه‌ی اول، دروازه روی یکی از کوتاه‌ترین مسیرهای کلید ← در گذاشته شده بود؛ یک انحراف هم‌طول وجود داشت که به سیاست بهینه اجازه می‌داد دروازه را کاملاً نادیده بگیرد، به همین دلیل به گلوگاه ساختاری منتقل شد. (رجوع کنید به بخش ۱۱).

اعتبار نقشه با جست‌وجوی سطح‌اول (BFS) قطعی بررسی می‌شود: باید مسیری از شروع به کلید با در بسته وجود داشته باشد و مسیری از کلید به هدف با در باز (دروازه عبورپذیر شمرده می‌شود؛ دروازه‌ی بسته فقط تأخیر ایجاد می‌کند و هرگز گراف را قطع نمی‌کند). نامزدهای نامعتبر به‌صورت بازتولید‌پذیر بازتولید می‌شدند ($\text{effective_seed} = \text{base_seed} \times 1000 + \text{attempt}$)؛ بذر 2 در تلاش شماره‌ی 0 موفق می‌شود و اجرای دوباره‌ی مولد، فایل `environments/maps/source.json` را بایست به‌بایت بازتولید می‌کند.

۲.۲ صورت‌بندی MDP

جدول ۱: صورت‌بندی رسمی مسئله به‌شکل یک فرایند تصمیم‌گیری مارکوف

مؤلفه	تعریف
فضای حالت S	$s = (r, c, \text{has_key}, \text{gate_phase})$ ؛ 233 خانه‌ی عبورپذیر $2796 = 2 \times 6 \times \text{حالت}$
فضای عمل A	بالا، پایین، چپ، راست (4 عمل)
تابع انتقال P	جهت موردنظر با احتمال $p = 0.8$ و هر یک از دو جهت عمود بر آن با $p = 0.1$ ؛ حرکت حاصل در برابر دیوارها، در قفل (بدون کلید مسدود) و دروازه‌ی بسته (فازهای 3 تا 5) ارزیابی می‌شود؛ هر پیامد مسدود، عامل را در جای خود نگه می‌دارد؛ <code>gate_phase</code> همواره به پیمانه‌ی 6 یک واحد جلو می‌رود؛ ورود به خانه‌ی کلید مقدار <code>has_key</code> را برابر 1 می‌کند
تابع پاداش R	بخش ۳.۲؛ دو نسخه‌ی اسپارس و شکل‌دهی شده با پتانسیل
ضریب تنزیل γ	مقدار مرجع 0.95؛ مقادیر $\{0.90, 0.95, 0.99\}$ در بخش ۳ بررسی شده‌اند
حالت‌های پایانی	خانه‌ی هدف (با هر وضعیت کلید و فاز)
سقف طول اپیزود	$3 \times 233 = 699$ گام (ضریب در فایل پیکربندی)
سیاست	$\pi(s) \rightarrow A$ ؛ سیاست‌های حریصانه‌ی قطعی میان الگوریتم‌ها مقایسه می‌شوند

خاصیت مارکوف

حالت کمینه‌ی خواسته‌شده در مشخصات، یعنی (x, y, k) ، دقیقاً با همان متغیری گسترش یافته که ویژگی پویای انتخاب‌شده ایجاب می‌کند. باز بودن در، تابعی از `has_key` است و باز بودن دروازه تابعی از `gate_phase`؛ با حضور هر دو در حالت، $P(s' | s, a)$ بدون هیچ ارجاعی به تاریخچه به‌خوبی تعریف می‌شود. بدون `gate_phase`، یک (x, y, k) یکسان گاهی مسدود و گاهی باز می‌بود، بسته به زمان رسیدن، که نقض آشکار خاصیت مارکوف است و Value Iteration حتی نمی‌توانست مدل خود را بنویسد. این پاسخ پرسش تحلیلی ۱ است (بخش ۱۰، Q1).

پایان یافتن در برابر قطع شدن

رسیدن به هدف، MDP را پایان می‌دهد؛ اما سقف گام صرفاً اپیزود را قطع می‌کند. این سقف یک سازوکار مربوط به طول اپیزود است، نه بخشی از MDP ایستا؛ Value Iteration به‌درستی آن را نادیده می‌گیرد و جمله‌ی راه‌اندازِ عامل‌های یادگیرنده فقط در پایان واقعی صفر می‌شود (`environments/maze.py` پرچم‌های `terminated` و `truncated` را جداگانه برمی‌گرداند).

محیط، مدل دقیق خود را از طریق `transitions(s, a)` به‌شکل `[(p, s', r, done), ...]` در دسترس می‌گذارد؛ این مدل از همان کد تحلیل حرکت ساخته می‌شود که `step()` از آن نمونه می‌گیرد، بنابراین مدلی که Value Iteration مصرف می‌کند و شبیه‌سازی‌ای که یادگیرنده‌ها تجربه می‌کنند هرگز واگرا نمی‌شوند.

هر گام، رویدادهای نام‌دار خود را نیز گزارش می‌کند: حرکت عادی، برخورد با دیوار، ورود به خانه‌ی جریمه، برداشتن کلید، تلاش برای عبور از درِ قفل، عبور از در، رسیدن به هدف و اتمام زمان (یعنی حداقل مجموعه‌ی خواسته‌شده) به‌علاوه‌ی `gate_blocked` برای ویژگی پویای ما. این رویدادها در دو سطح دانه‌بندی در گزارش‌های ذخیره‌شده ثبت می‌شوند: شمارش‌های هر اپیزود در فایل‌های CSV آموزش `key_picked`, `door_passes`, `locked_door_attempts`, `gate_blocked`, `penalty_entries`, `wall_hits`, `timeout`, `success` و رویدادهای نام‌دار در تک‌تک سطرهای گزارش‌های ردیابی به‌روزرسانی گام‌به‌گام (بخش‌های ۴ و ۲.۵).

۳.۲ طراحی پاداش (دو نسخه)

نسخه‌ی اسپارس (خط پایه‌ی مقایسه)

هر گام ۱-، برخورد با دیوار ۵-، خانه‌ی جریمه ۱۰-، تلاش برای عبور از درِ قفل ۲-، برخورد با دروازه ۲-، برداشتن کلید ۵۰+، رسیدن به هدف ۲۰۰+، و عبور از در ۰. پاداش صفر برای عبور از درِ عمدی است: هر پاداش مثبت تکرارپذیر روی یک خانه‌ی غیرپایانی را می‌توان با رفت‌وبرگشت از آن استخراج کرد (پاداش منهای دو هزینه‌ی گام در هر حلقه)؛ با این حال رویداد آن همچنان ثبت می‌شود.

نسخه‌ی شکل‌دهی‌شده

نسخه‌ی اسپارس به‌علاوه‌ی شکل‌دهی مبتنی بر پتانسیل:

$$F = \gamma \Phi(s') - \Phi(s)$$

که در آن $\Phi(s)$ برابر منفی فاصله‌ی باقی‌مانده‌ی مأموریت بر حسب BFS است: پیش از برداشتن کلید، فاصله تا کلید به‌علاوه‌ی فاصله‌ی کلید تا هدف؛ پس از آن، فاصله تا هدف؛ و $\Phi(\text{هدف}) = 0$.

تابع Φ عاقدانه در لحظه‌ی برداشتن کلید پیوسته است: فاصله‌های ساده‌لوحانه‌ی هر زیرهدف، دقیقاً در همان لحظه که عامل به زیرهدف می‌رسد، به‌اندازه‌ی (هدف $\rightarrow$ کلید) $-\gamma \cdot d$ جهش می‌کردند و در عمل موفقیت را جریمه می‌کردند. چون شکل‌دهی مبتنی بر

پتانسیل است (نگ و همکاران، 1999) و γ شکل‌دهی با γ عامل برابر است، سیاست بهینه به‌طور اثبات‌پذیر تغییر نمی‌کند، که در بخش ۵ به‌صورت تجربی نیز تأیید شده است. به‌عنوان یک واریسی عددی، روی مسیر بهینه‌ی نوشته‌شده‌ی 33 گامی، بازگشتِ شکل‌دهی شده دقیقاً به‌اندازه‌ی مجموع تلسکوپیِ پتانسیل (59.4) از بازگشتِ اسپارس بیشتر است.

۴.۲ راستی‌آزمایی

60 آزمون واحد (پوشه‌ی tests/) محیط را مهار می‌کنند: مجموع احتمال‌های انتقال برای هر 4×2796 زوج حالت-عمل برابر 1 است؛ گام‌های نمونه‌گیری‌شده همواره در تکیه‌گاه مدل افشاشده قرار می‌گیرند؛ نويز تجربی عمل روی 3000 گام برابر $0.8/0.1/0.1$ است؛ هر قاعده‌ی دینامیک (دیوار، در، دروازه بر حسب فاز، یک‌بارگی کلید، جریمه، پایان در هدف و اتمام زمان) آزمون اختصاصی خود را دارد؛ اثبات می‌شود که شکل‌دهی مبتنی بر پتانسیل و حافظ دینامیک است؛ مولد برای هر ده بذر پایه‌ی ممکن نقشه‌ی معتبر تولید می‌کند؛ مهر و موم بودن هدف بدون در اثبات می‌شود؛ و خود به‌روزرسانی‌های یادگیری (بخش‌های ۵ و ۶) و ساخت جدول‌های انتقال (بخش ۸) نیز آزموده شده‌اند.

۳ Value Iteration

این الگوریتم از پایه پیاده‌سازی شده است (agents/value_iteration.py) و به شکل پس‌انتشارهای بهینگی بلمن روی مدل دقیق عمل می‌کند؛ همگرایی زمانی اعلام می‌شود که


$$\max_s |V_{k+1}(s) - V_k(s)| < 10^{-6}$$

کتابخانه‌ی NumPy تنها پس‌انتشار خودمان را روی آرایه‌های انتقال لایه‌گذاری شده تبدیل به بردار می‌کند. سیاست حریصانه‌ی استخراج‌شده از V^* مرجع هر دو روش بدون مدل است.

جدول ۲: اثر ضریب تنزیل بر همگرایی و کیفیت سیاست

γ	جاروب تا همگرایی	V (شروع)	نرخ موفقیت	بازگشت	گام	توافق سیاست با $\gamma = 0.95$
0.90	80	-9.79	100%	191.51	43.3	97.9%
0.95	91	9.60	100%	191.61	43.4	- (مرجع)
0.99	102	119.43	100%	191.99	43.6	96.6%


(پروتکل ارزیابی در اینجا و در سراسر گزارش: 500 اپیزود حریصانه روی محیط تصادفی با بذر ارزیابی 999. زمان اجرا برای هر γ حدود 0.02--0.03 ثانیه است.)



شکل ۱: منحنی‌های همگرایی Value Iteration برای سه مقدار γ


منحنی‌های همگرایی دو دسته بندی را نشان می‌دهند. در حدود 45 جاروب نخست، بیشینه‌ی تغییر مقدار روی یک سطح باقی می‌ماند: اطلاعات پاداش هنوز در حال انتشار به عقب در طول مسیر بهینه‌ی حدوداً 33 گامی است، یک گام در هر جاروب، بنابراین بزرگ‌ترین به‌روزرسانی‌ها به جای کوچک شدن، مقیاس هزینه‌ی گام را دنبال می‌کنند. به محض آن که تخمین‌های مقدار، شروع را به هدف وصل می‌کنند، نگاشت انقباضی کنترل را به دست می‌گیرد و خطا با شیب $\ln \gamma$ به‌طور هندسی افت می‌کند، که برای γ کوچک‌تر آشکارا

تندتر است. به همین دلیل تعداد تکرارها تا رسیدن به آستانه با γ افزایش می‌یابد ($80 \rightarrow 91 \rightarrow 102$); ضریب تنزیل بزرگ‌تر کندتر منقبض می‌شود. خط آستانه در 10^{-6} همان معیار توقف پیکربندی شده است.



شکل ۲: نقشه‌ی حرارتی تابع مقدار (بیشینه روی فازهای دروازه) در $\gamma = 0.95$

تابع مقدار ساختار مأموریت را مستقیماً نشان می‌دهد: بدون کلید (پانل چپ) مقدار به سمت خانه‌ی کلید بالا می‌رود؛ با کلید (پانل راست) گرادینان به سوی محفظه جهت‌گیری مجدد می‌کند. پانل $k = 0$ مقادیر بالایی را درون محفظه نشان می‌دهد، هرچند آن حالت‌ها بدون کلید دست‌نیافتنی‌اند؛ در، ورود را کنترل می‌کند نه خود هدف را، پس عاملی بی‌کلید که در آنجا قرار داده شود همچنان می‌تواند مأموریت را تمام کند؛ این خاصیتی از فضای حالت است، نه یک اشکال. مقادیر میان مقادیر مختلف γ به شدت تفاوت می‌کنند (شروع V از -9.8 ، جایی که پاداش‌های پایانی تنزیل شده دیگر هزینه‌ی انباشته‌ی گام‌ها را پوشش نمی‌دهند، تا $+119.4$) در حالی که هر سه سیاست از نظر رفتاری تقریباً یکسان‌اند؛ مقیاس مقدار چیزی درباره‌ی کیفیت سیاست نمی‌گوید.



شکل ۳: سیاست بهینه به تفکیک فاز دروازه در $\gamma = 0.95$

این شکل، شاهد اصلی آن است که دروازه‌ی دوره‌ای واقعاً تصمیم‌گیری را شکل می‌دهد. دور از دروازه، پیکان‌ها نسبت به فاز تغییر ناپذیر هستند (عاملی که ده گام فاصله دارد به فاز کنونی اهمیت نمی‌دهد، چون تا زمان رسیدن چرخیده است). اما در نزدیکی ورودی محفظه، عمل بهینه در همان خانه با همان وضعیت کلید بر حسب فاز تفاوت می‌کند: در فازهای باز 0 تا 2 پیکان‌ها به درون دروازه اشاره می‌کنند؛ در فازهای 3 و 4 رو به بیرون دارند (پیمودن یک انحراف دوگامی بهتر از پرداخت مکرر 2- است؛ رسیدن در فاز 3 ارزشی برابر 96.1 دارد در برابر 119.9 در فاز 0، یعنی جریمه‌ی زمانی حدوداً 24 واحدی)؛ و در فاز 5 عمل بهینه آن است که یک بار عامدانه به دروازه‌ی بسته برخورد کند، چون فاز سرریز می‌شود و همان حرکت بعدی از دروازه عبور می‌کند. یک برخورد ارزان بهتر از یک انحراف است؛ Value Iteration دقیقاً در حال شمردن گام‌هاست.

۴ الگوریتم Q-Learning

کنترل Temporal Difference جدولی و Off-Policy (agents/q_learning.py) با رفتار ϵ -greedy. جزئیات پیاده‌سازی که اهمیت دارند:

- شکستن تصادفی تساوی‌ها: با مقداردهی اولیه‌ی صفر، یک $\arg \max$ قطعی همیشه عمل 0 را انتخاب می‌کند و اکتشاف را سوگیر می‌ساخت.
 - جمله‌ی راه‌انداز: $\max_{a'} Q(s', a')$ تنها در پایان واقعی صفر می‌شود (بخش ۲.۲).
 - شمارش بازدید: شمارنده‌ی بازدید هر حالت نگهداری و همراه جدول Q ذخیره می‌شود.
- ابزارامترها (از فایل پیکربندی): $\alpha = 0.1$, $\gamma = 0.95$, $\epsilon : 1.0 \rightarrow 0.05$, 5000 اپیزود و بذرها $\{7, 21, 42\}$.

بازسازی دستی یک به‌روزرسانی

(الزام مشخصات پروژه؛ برگرفته از فایل ثبت‌شده‌ی results/raw_data/q_learning/q_update_trace.csv, اپیزود 2500, $\alpha = 0.1$, $\gamma = 0.95$) در حالت $(s = (0, 1, k = 0, p = 0))$ با عمل «چپ»، پاداش -1 و حالت بعدی $s' = (0, 0, k = 0, p = 1)$

$$\text{target} = r + \gamma \max_{a'} Q(s', a') = -1 + 0.95 \times (-11.006227) = -11.455916$$

$$\delta = \text{target} - Q(s, a) = -11.455916 - (-13.278179) = 1.822263$$


$$Q(s, a) \leftarrow -13.278179 + 0.1 \times 1.822263 = -13.095952$$

که دقیقاً با مقدار ثبت‌شده در فایل گزارش مطابقت دارد.

۱.۴ زمان‌بندی‌های کاهش ϵ

جدول ۳: مقایسه‌ی زمان‌بندی خطی و نمایی کاهش ϵ (هر کدام روی 3 بذری)

اجرا	اپیزود تا موفقیت 90%	بازگشت ارزیابی	توافق با سیاست Value Iteration
اسپارس / خطی	≈ 1546	190.8--191.6	57.9--58.6%
اسپارس / نمایی	≈ 1099	189.4--190.5	51.2--51.9%




شکل ۴: مقایسه‌ی زمان‌بندی‌های کاهش ϵ در Q-Learning

کاهش نمایی حدود 1.4 برابر زودتر به موفقیت پایدار می‌رسد، چون ϵ سریع‌تر فرو می‌ریزد و عامل زودتر بهره‌برداری می‌کند؛ که در هر سه پانل با نوارهای باریکِ بذرها دیده می‌شود. بهای این کار، پوشش است: کاهش خطی مدت بیشتری اکتشاف می‌کند و در پایان توافق آشکارا بالاتری با سیاست بهینه در سراسر فضای حالت دارد (58% در برابر 51%)، در حالی که هر دو زمان‌بندی به مجانب یکسانی می‌رسند (موفقیت 100% و بازگشت حدود 190). سرعت یادگیری و پوشش فضای حالت با یکدیگر مبادله می‌شوند؛ هیچ‌کدام از دو زمان‌بندی به‌طور بی‌قیدوشرط «بهتر» نیست.

۲.۴ پاداش اسپارس در برابر پاداش شکل‌دهی‌شده


جدول ۴: اثر شکل‌دهی پاداش بر سرعت یادگیری (هر کدام روی 3 بذری)

اجرا	اپیزود تا موفقیت 90%	بازگشت ارزیابی
اسپارس / نمایی	≈ 1099	189.4--190.5
شکل‌دهی‌شده / نمایی	≈ 380	189.2--190.6



شکل ۵: اثر شکل‌دهی پاداش بر منحنی‌های یادگیری Q-Learning

شکل‌دهی، جهشِ آغازینی حدوداً 3 برابری ایجاد می‌کند: نرخ یافتن کلید تقریباً بلافاصله اشباع می‌شود (گرادیان پتانسیل به‌معنای واقعی کلمه به کلید اشاره می‌کند) و موفقیت 90% در اپیزود 380 $\approx$ به‌جای 1099 $\approx$ به‌دست می‌آید. مهم‌تر این‌که بازگشت‌های نهایی در هر 12 اجرا از نظر آماری یکسان‌اند؛ همان پیش‌بینی تغییر ناپذیری مبتنی بر پتانسیل در بخش ۳.۲ که اینجا تجربی تأیید می‌شود: شکل‌دهی یادگیری را شتاب داده بدون آن‌که کیفیت سیاست نهایی را تغییر دهد. رفتار ناخواسته‌ای هم القا نکرده است: ورود به خانه‌های جریمه در ارزیابی (0.21--0.27 در هر اپیزود)، برخورد با دیوار (2.2--2.5)، برخورد با دروازه (0.45--0.22) و تعداد گام‌ها (حدود 44--46) میان دو نسخه قابل تمیز نیستند؛ نه حلقه‌ای، نه استخراج پاداش جانبی، و نه پرهیز افراطی از جریمه. نکته‌ی جالب آن‌که سیاست‌های حریصانه‌ی آموخته‌شده با پاداش اسپارس و شکل‌دهی‌شده تنها روی 49.3% از حالت‌های مشترکاً بازدیدشده توافق دارند در حالی که عملکردی یکسان دارند. (به تحلیل تساوی‌های تقریبی در بخش ۶ رجوع کنید).



شکل ۶: نقشه‌ی بازدید حالت‌ها در Q-Learning (مقیاس لگاریتمی)

نقشه‌ی بازدید (مقیاس لگاریتمی، از خروجی‌های الزامی) مستند می‌کند که تجربه به کجا رفته است، و سه نشانه معنانشناسی محیط را تأیید می‌کنند: خانه‌ی کلید هیچ بازدیدی با $k = 0$ ندارد، چون ورود به آن بلافاصله `has_key` را تغییر می‌دهد؛ این خانه هرگز یک حالت تصمیم نیست؛ محفظه هیچ بازدید بی‌کلیدی ندارد (ساختاراً دست‌نیافتنی، بخش ۱.۲)؛ و با در اختیار داشتن کلید، مسیر دروازه/در از تاریک‌ترین نواحی است؛ گلوگاه، هر اپیزود موفق را هدایت می‌کند و انتظار پشت دروازه‌ی بسته بازدیدها را بیشتر متمرکز می‌سازد.

۵ الگوریتم SARSA با Eligibility Traces


کنترل جدولی On-Policy با Eligibility Traces (agents/sarsa_lambda.py): هدف بهروزرسانی از $Q(s', a')$ برای عملی استفاده می‌کند که سیاست ϵ -greedy واقعاً انتخاب و سپس اجرا می‌کند.

Replacing Traces به جای Eligibility Traces انتخاب شدند: با نویز لغزش 20%، عامل درون یک اپیزود حالت‌ها را بازدید مجدد می‌کند و ردهای انباشتی می‌توانند از 1 فراتر روند و با شمارش مضاعف، بهروزرسانی‌های λ بالا را ناپایدار کنند؛ Replacing Traces شایستگی را در سقف 1 نگه می‌دارند (سینق و ساتن، 1996). ردها در هر اپیزود بازنشانی و زیر 10^{-4} هرس می‌شوند، که مجموعه‌ی فعال را در $\gamma\lambda = 0.855$ به حدود 60 زوج محدود می‌کند و اثر عددی ناچیزی دارد. آزمون‌های واحد تأیید می‌کنند که $\lambda = 0$ دقیقاً به SARSA یک‌گامی فرو می‌کاهد و این‌که خطای Temporal Difference گام دوم، زوج گام اول را دقیقاً به‌اندازه‌ی $\alpha \cdot \delta \cdot \gamma\lambda$ به‌روز می‌کند.

۱.۵ جاروب λ


جدول ۵: اثر λ بر سرعت و پایداری یادگیری

λ	اپیزود تا موفقیت 90%	انحراف معیار بازگشت اواخر آموزش	بازگشت ارزیابی
0	1670	26.0--72.0	185.1--188.1
0.3	1334	22.6--45.4	187.6--190.7
0.7	982	16.5--24.4	189.5--190.8
0.9	805	16.5--31.6	187.0--189.1



شکل ۷: جاروب مقادیر λ در الگوریتم SARSA

سرعت یادگیری به‌طور یکنوا با λ افزایش می‌یابد، چهار منحنی موفقیت در ترتیبی کامل قرار می‌گیرند و $\lambda = 0.9$ دو برابر سریع‌تر از $\lambda = 0$ به موفقیت پایدار می‌رسد، زیرا هر خطای Temporal Difference به‌جای یک حالت، کل مسیر اخیر را به‌روز می‌کند. اما سرعت همه‌ی داستان نیست: ردهای بلند $\lambda = 0.9$ دلتای لغزش‌های اکتشافی را نیز به‌عقب منتشر می‌کنند و در همگرایی نویز تزریق می‌کنند (واریانس بالاتر در اواخر اجرا و مقادیر نهایی اندکی پایین‌تر)، در حالی که $\lambda = 0$ هم کندترین و هم کم‌پایدارترین گزینه در میان بذرهاست، چون پس‌انتشارهای تک‌گامی مقادیر کهنه‌ی دوردست را بسیار آهسته اصلاح می‌کنند. مقدار $\lambda = 0.7$ بهترین توازن را می‌دهد: حدود 1.7 برابر سریع‌تر از $\lambda = 0$ با کمترین و یکنواخت‌ترین واریانس پایانی و بهترین بازگشت‌های نهایی (پرسش تحلیلی ۴، بخش ۱۰).

۲.۵ رفتار δ و E در طول یک اپیزود

شکل ۸: خطای Temporal Difference δ و Eligibility Traces E در اپیزود 4900

برای اپیزود ردیابی شده‌ی 4900 (49 گام؛ داده‌های خام در `sarsa_step_trace.csv` و `sarsa_trace_dump.csv`): در این نقطه مقادیر همگرا شده‌اند، پس δ نزدیک صفر نوسان می‌کند و تنها هنگام لغزش‌های تصادفی جهش می‌کند، به شدت منفی (حدود -43) وقتی لغزش پیامدی بدتر از انتظار (دیوار یا جریمه) تولید می‌کند و مثبت (حدود +27) در بازیابی‌های بهتر از انتظار. به‌طور مشخص، گام‌های 1 و 2 لغزش‌های عمود به مرز بودند ($r = -6$) با $\delta = -8.68$ و $\delta = -4.28$ ، در حالی که گام‌های 4 تا 6 حرکت‌های متمرکز مسیری با دلتاهای مثبت کوچک بودند (+1.28، +2.88 و +1.40).

پانل سمت راست، شایستگی چهار زوج حالت-عمل نخست را به شکل خطوط راست موازی روی محور لگاریتمی نشان می‌دهد: دقیقاً $(\gamma\lambda)^t = 0.855^t$ ؛ بنابراین یک شگفتی در گام 10 همچنان حدود دو دوجین زوج حالت-عمل پیشین را با وزنی که به‌طور هندسی کاهش می‌یابد جابه‌جا می‌کند. این همان اسناد اعتبار به کمک Eligibility Traces است که مرئی شده است.


۶ مقایسه‌ی سه الگوریتم

هر سه الگوریتم روی نقشه‌ی یکسان و با پاداش اسپارس یکسان اجرا شده‌اند؛ عامل‌های مرجع عبارت‌اند از Value Iteration ($\gamma = 0.95$)، Q-Learning (اسپارس/نمایی، بذر 7) و SARSA با $\lambda = 0.7$ (بذر 7). داده‌ها در فایل `comparison_summary.csv` قرار دارند.

جدول ۶: مقایسه‌ی کمی سه الگوریتم روی نقشه‌ی مبدأ

معیار	Value Iteration	Q-Learning	SARSA(0.7)
نوع	مبتنی بر مدل	بدون مدل، Off-Policy	بدون مدل، On-Policy
زمان اجرا	0.1 ثانیه	7.8 ثانیه	54.1 ثانیه
نمونه تا موفقیت 90%	- (مدل دارد)	612,908	526,282
کل نمونه‌های محیط (5000 اپیزود)	0	850,601	769,145
اندازه‌ی فایل مدل	103 KB	271 KB	274 KB
بازگشت / گام ارزیابی	191.6 / 43.4	190.0 / 45.6	190.6 / 44.4
(شروع) V^π ، دقیق	9.60 = V^*	5.93	7.83
توافق خام با Value Iteration	-	51.4%	51.9%
ورود به جریحه در هر اپیزود	0.260	0.236	0.188

(زمان‌های اجرای مطلق با بار ماشین تغییر می‌کنند؛ آن‌چه پایدار است **نسبت‌ها** هستند: Value Iteration حدود 70 تا 80 برابر سریع‌تر از Q-Learning، و حلقه‌ی ردهای SARSA حدود 7 برابر کندتر از Q-Learning).




شکل ۹: منحنی‌های یادگیری دو روش بدون مدل

دو روش بدون مدل مسیر یکسانی را می‌پیمایند، اتمام زمان در گام تصادفی، برخاست، و همگرایی، و SARSA(0.7) به‌طور پیوسته از نظر تعداد اپیزود و نمونه جلوتر است (حدود 14% گام کمتر تا موفقیت پایدار): ردهای آن، کارایی نمونه را به بهای محاسبه‌ی بیشتر در هر گام می‌خرند. Value Iteration اصلاً روی این محورها ظاهر نمی‌شود، و همین خود مقایسه است: با در اختیار داشتن مدل انتقال دقیق، سیاست بهینه را در یک‌دهم ثانیه و با صفر نمونه تولید می‌کند، در حالی که روش‌های بدون مدل حدود 500 تا 600 هزار تعامل با محیط را برای سیاست‌هایی نزدیک به بهینه می‌پردازند.


همچنین توجه کنید که «تزدیک به بهینه» دقیقاً چه معنایی دارد: با ارزیابی زیر مدل دقیق، سیاست Q-Learning در حالت شروع ارزش 5.93 و سیاست SARSA(0.7) ارزش 7.83 دارد، در برابر $V^* = 9.60$ ، یعنی سیاست آموخته‌شده‌ی SARSA در اینجا واقعاً بهتر است، با وجود توافق خام تقریباً یکسان. پس ارزیابی دقیق سیاست، عدسی بسیار تیزتری از درصدهای تطابق عمل است.

اثر تساوی تقریبی

توافق خام با Value Iteration برای هر دو یادگیرنده تنها حدود 51% است، هرچند هر دو بیش از 95% بازگشت بهینه را جمع می‌کنند. توضیح، که در برابر Q^* دقیق محاسبه شده، این است: در 41.1% از حالت‌های غیر پایانی، عمل دومی وجود دارد که فاصله‌اش تا بهینه کمتر از 1.0 است (و در 28.6% کمتر از 0.5)، مسیرهایی که دو جهت در آن‌ها به یک اندازه خوب‌اند، و تخمین‌های جدولی نویزی، چنین تساوی‌هایی را دلبخواهی می‌شکنند. تنها حدود 19% از اختلاف‌های واقعی، تساوی تقریبی‌اند (فاصله‌ی کمتر از 0.5)؛ باقی در حالت‌های کم‌بازدید خارج از مسیر قرار دارند که فاصله‌های بزرگشان تأثیر اندکی بر V^π (شروع) دارد، چون سیاست حریصانه تقریباً هرگز واردشان نمی‌شود.




شکل ۱۰: نقشه‌ی توافق و اختلاف Q-Learning با Value Iteration



شکل ۱۱: نقشه‌ی توافق و اختلاف SARSA(0.7) با Value Iteration

نقشه‌های رنگی توافق/اختلاف داستان چگالی بازدید را مکانی می‌کنند: آبی (توافق در تمام فازهای دروازه) دقیقاً مسیرهای مأموریت را در بر می‌گیرد: قلمرو شروع ← کلید در پانل‌های $k = 0$ و مسیر کلید ← در ← هدف در $k = 1$. در حالی که قرمز روی نواحی‌ای پراکنده است که سیاست همگرا شده هرگز به آن‌ها نیاز ندارد؛ محفظه در $k = 0$ خالی است چون بدون کلید دست‌نیافتنی است. روش‌های جدولی دقت خود را همان‌جا متمرکز می‌کنند که تجربه‌شان رفته است؛ جایی که داده کمیاب است، عمل حریصانه تقریباً دلبخواهی است، و اهمیتی هم ندارد، چون آن حالت‌ها خارج از سیاست‌اند.



شکل ۱۲: مسیرهای حریصانه‌ی نهایی هر سه الگوریتم زیر جریان لغزش یکسان

شکل مسیر نهایی، مکمل On-Policy نقشه‌های اختلاف است: یک اپیزود ارزیابی حریصانه برای هر الگوریتم، همه زیر جریان لغزش یکسان بذر 999، پس هر تفاوتی میان پانل‌ها تفاوت سیاست است نه شانس. خط پایانی برای هر سه یکسان است، 45 گام و بازگشت 198، که به صورت $+250$ (کلید و هدف) منهای 45 هزینه‌ی گام، منهای 5 برای یک برخورد با دیوار ناشی از لغزش و منهای 2 برای یک انتظار پشت دروازه‌ی بسته تجزیه می‌شود، اما مسیرها یکسان نیستند: Q-Learning از مسیرهای داخلی حوالی سطرها 5 تا 9 میان‌بر می‌زند، در حالی که Value Iteration و SARSA(0.7) لبه‌ی غربی را تا سطر 10 دنبال می‌کنند.

این همان تحلیل تساوی تقریبی است که مشخص شده: انتخاب‌های حریصانه‌ی متفاوت در مسیرهای هم‌قیمت، مسیرهای متفاوت با ارزش دقیقاً برابر تولید می‌کنند، و به همین دلیل توافق خام حدود 51% با بازگشت‌های یکسان هم‌زیستی دارد. در واقع، بازپخش عمل‌های موردنظر هر سیاست با غیرفعال کردن لغزش، برای هر سه عامل دقیقاً 33 حرکت می‌پیماید، همان کران پایین BFS برای مأموریت شروع ← کلید ← هدف، پس آن حدود 10 حرکت اضافی محقق شده تماماً بهای نرخ لغزش 20% است، نه اتلاف مسیریابی. انشعاب‌های کوتاه بن‌بست (در Q-Learning نزدیک (4,2) و در تکرار مقدار درست جنوب‌غربی هدف) لغزش‌های عمود و سپس تصحیح فوری‌اند: همان دینامیک 0.8/0.1/0.1 در عمل. و هر مسیر از دنباله‌ی ستاره ← دروازه ← لوزی عبور می‌کند: هر عامل دقیقاً یک انتظار 2- پشت دروازه می‌پردازد، که تأیید می‌کند گلوگاه را نمی‌توان کاملاً دور زد، فقط می‌توان زمان‌بندی فاز کرد. محدودیت این شکل ذاتی است: این تنها یک اپیزود با یک بذر نماینده هست (45 گام درون بازه‌ی میانگین 43.4--45.6 جدول بالا می‌نشیند) اما بار مقایسه را جدول تجمیعی به دوش می‌کشد، نه این تصویر.

سه حالت نمونه

(از فایل comparison_sample_states.csv، انتخاب‌شده بر پایه‌ی سازوکارهای متمایز):

- مجاور جریمه: $(2,1)$ ، $k = 0$ ، فاز 4، 669 بازدید:

Value Iteration «راست»، SARSA «چپ» (فاصله‌ی 3.13). این خانه با خانه‌ی جریمه‌ی (3,1) همسایه است؛ SARSA انحرافی را آموخته که ریسک لغزش را از چاله‌ی 10- دور نگه می‌دارد. این همان حاشیه‌ی ایمنی On-Policy است، به‌صورت کمی: لغزش‌های اکتشافی خودِ عامل به درون چاله در حین آموزش، در مقادیر Q آن قیمت‌گذاری شده‌اند.

- تساوی تقریبی در محفظه : (15,15)، $k = 1$ ، فاز 1، 1418 بازدید: Value Iteration «پایین»، Q-Learning «راست»، فاصله دقیقاً 0.000. دو مسیر دوگامی متقارن به هدف هستند و «اختلاف» صرفاً یک تشریفات تساوی‌شکنی است.
- روی خودِ دروازه : (14,12)، $k = 1$ ، فاز 0، 5 بازدید: Value Iteration «راست» (در یک گام فاصله دارد)، Q-Learning «پایین»، فاصله‌ی 19.7. عامل‌ها از دروازه عبور می‌کنند اما تقریباً هرگز روی آن نمی‌ایستند، پس با پنج بازدید، تخمین هرگز درگاه را یاد نگرفت. خطاهای بزرگ آن‌جا زندگی می‌کنند که داده کمیاب است.

۷ یادگیری انتقالی (با Q-Learning)

۱.۷ محیط‌های هدف

هر دو محیط به صورت قطعی از محیط مبدأ مشتق می‌شوند (perturb_map، اعتبارسنجی شده با BFS، بدون دست‌زدن به محفظه، در، دروازه و شروع؛ دیوارها فقط جابه‌جا می‌شوند تا قید تعداد دیوار حفظ شود):

جدول ۷: مشخصات دو محیط هدف انتقال

ویژگی	هدف مشابه	هدف متفاوت
دیوارهای جابه‌جاشده	11/56 = 19.6%	20/56 = 35.7%
کلید	بدون تغییر (12,10)	منتقل شده به (5,15)
خانه‌های جریمه	بدون تغییر (6)	9 → +3


در هدف متفاوت، محل قدیمی کلید به یک مسیر ساده تبدیل می‌شود، یک تله‌ی آموزشی برای انتقال منفی برای هر سیاستی که روی مبدأ آموزش دیده باشد، و کلید جدید دوباره کنار یک خانه‌ی جریمه می‌نشیند و همان الگوی «برداشت پرخطر» را در زمینی تازه بازآفرینی می‌کند.

۲.۷ سناریوها و نتایج

چهار سناریوی خواسته‌شده: آموزش از صفر (جدول Q صفر، خط پایه)، انتقال کامل، انتقال مقیاس شده با $Q_0 = \beta \cdot Q_{\text{source}}$ برای $\beta \in \{0.25, 0.5, 0.75\}$ ، و انتقال گزینشی (فقط حالت‌هایی که همسایگی 3×3 آن‌ها میان دو نقشه تغییر نکرده است: 1356 از 2724 حالت مبدأ برای هدف مشابه و 672 حالت برای هدف متفاوت). همه‌ی سناریوها 5000 اپیزود، $0.05 \rightarrow 0.3$: ε و 3 بذر مشترک دارند. جهش آغازین به صورت ارزیابی حریصانه‌ی جدول اولیه پیش از هر آموزشی سنجیده می‌شود (200 اپیزود) - توجه کنید که سناریوی آموزش از صفر با ε اولیه‌ی پایین ضرر نمی‌کند، چون جدول Q مقداردهی شده با صفر و تساوی‌شکنی تصادفی، عملاً مانند $1 \approx \varepsilon$ اکتشاف می‌کند. بهینه‌ی اهداف (طبق Value Iteration): هدف مشابه 192.5 و هدف متفاوت 179.8.


جدول ۸: نتایج سناریوهای انتقال روی هر دو هدف

هدف	سناریو	جهش آغازین (موفقیت / بازگشت)	اپیزود تا 90%	بازگشت نهایی
مشابه	از صفر	-3670 / 0%	718	181.8
مشابه	کامل	-139 / 100%	99	185.2
مشابه	مقیاس شده $\beta = 0.25$	-139 / 100%	99	190.2
مشابه	مقیاس شده $\beta = 0.50$	-139 / 100%	99	189.3
مشابه	مقیاس شده $\beta = 0.75$	-139 / 100%	99	185.7
مشابه	گزینشی	-2777 / 0%	132	186.1
متفاوت	از صفر	-3634 / 0%	849	164.6
متفاوت	کامل	-3573 / 0%	691	164.0
متفاوت	مقیاس شده $\beta = 0.25$	-3573 / 0%	500	166.4
متفاوت	مقیاس شده $\beta = 0.50$	-3573 / 0%	478	165.2
متفاوت	مقیاس شده $\beta = 0.75$	-3573 / 0%	622	165.1
متفاوت	گزینشی	-3539 / 0%	519	163.8




شکل ۱۳: منحنی‌های سناریوهای انتقال روی هدف مشابه

روی هدف مشابه، انتقال مثبت است: جدول‌های منتقل‌شده در 100% از اپیزودهای حریصانه‌ی پیش از آموزش موفق می‌شوند (البته کند، انحراف از 11 دیوار جابه‌جاشده بازگشت 139- را توضیح می‌دهد) و از نخستین پنجره‌ی قابل‌اندازه‌گیری (اپیزود 99) موفقیت 90% را حفظ می‌کنند، یعنی حدود 7 برابر زودتر از آموزش از صفر (718). انتقال گزینشی، با وجود شکست در ارزیابی جهش آغازین (جدول ناقص آن دقیقاً همان جاهایی حفره دارد که نقشه تغییر کرده)، تقریباً تمام مزیت سرعت را بازمی‌یابد (132)، نیمه‌ی منتقل‌شده‌ی فضای حالت همان نیمه‌ای است که هنوز اهمیت دارد.




شکل ۱۴: مقایسه‌ی جدول Q پیش و پس از انتقال روی هدف مشابه

نمای پیش/پس از انتقال خواسته‌شده در مشخصات (انتقال کامل، بذر 7): در بالا، بیشینه‌ی $|\Delta Q|$ روی عمل‌ها برای هر خانه، و در پایین سهم فازهای دروازه‌ای که عمل حریصانه‌ی آن‌ها پس از 5000 اپیزود هدف باقی مانده است. در فضای Q ، مفهوم «مشابه» کمی می‌شود: میانگین بیشینه‌ی $|\Delta Q|$ تنها 6.5 در $k=0$ و 3.3 در $k=1$ است، و عمل حریصانه‌ی منتقل‌شده در 68% / 83% از حالت‌های دارای داده باقی می‌ماند، سطر پایین در امتداد هر چیزی که مأموریت واقعاً استفاده می‌کند آبی می‌ماند. آن‌چه بازنویسی می‌شود موضعی و خواناست: انحراف‌های قیمت‌گذاری مجدد پیرامون یازده دیوار جابه‌جاشده (نوار میانی نقشه در $k=0$)؛ در حالی که بزرگ‌ترین بازنویسی منفرد، (16,14) با کلید، در گوشه‌ی محفظه، اصلاً تغییر زمین نیست (محفظه دست‌نخورده است) بلکه یک نوسازی داده است: 189 بازدید در مبدأ، عمل‌های غیرحریصانه‌ی آن گوشه را کهنه و پایین نگه داشته بود (مثلاً q_{up} برابر 49.6 در برابر مقدار نوسازی‌شده‌ی حدود 137)، سپس 613 بازدید در هدف آن‌ها را بالا کشید، و عمل حریصانه هرگز تغییر نکرد. اندازه‌ی $|\Delta Q|$ و تغییر سیاست دو چیز متفاوت‌اند؛ لکه‌های قرمز بالا راست حالت معکوس‌اند؛ حالت‌های خارج از مسیر با تساوی تقریبی که عمل حریصانه‌شان با به‌روزرسانی‌های کوچک برمی‌گردد، بدون هیچ پیامدی.



شکل ۱۵: منحنی‌های سناریوهای انتقال روی هدف متفاوت


روی هدف متفاوت، انتقال آنچنان ساده نیست: جهش آغازین انتقال کامل، موفقیت 0% است، به‌سختی بالاتر از آموزش از صفر، زیرا سیاست به‌ارث‌رسیده با اطمینان به‌سوی جایی می‌رود که کلید قبلاً آن‌جا بود. با این حال سرعت یادگیری اندکی بهبود می‌یابد (691 در برابر 849 اپیزود)، چون نیمه‌ی «با کلید» جدول و مسیرهای تغییرنکرده همچنان مفیدند. منحنی انتقال کامل حوالی اپیزودهای 200 تا 400 آشکارا حتی از آموزش از صفر عقب می‌ماند و سپس بازمی‌گردد: امضای جمعیتی زودرن انتقال منفی.



شکل ۱۶: مقایسه‌ی جدول Q پیش و پس از انتقال روی هدف متفاوت

همان نمای پیش/پس روی هدف متفاوت، انتقال منفی را به شکل مکانی نمایش می‌دهد. به روزرسانی‌ها حدود 4 برابر بزرگ‌تر از هدف مشابه‌اند (میانگین بیشینه‌ی $|\Delta Q|$ برابر 23.9 در $k=0$ با اوج 136.9)، و کانون تاریک پانل $k=0$ دقیقاً **حوضه‌ی کلید قدیمی** پیرامون (12,10) است؛ ناحیه‌ای که جدول منتقل‌شده با بیشترین اطمینان در آن اشتباه بود، پس هر مقدار به‌ارث‌رسیده باید عوض می‌شد؛ حالتی که در بخش ۳.۷ بررسی می‌شود درون همین حوضه قرار دارد و عمل حریصانه‌اش در مجموعه‌ی بازنویسی‌شده‌هاست. تنها 33% از حالت‌های بی‌کلید، عمل حریصانه‌ی منتقل‌شده‌ی خود را حفظ می‌کنند.

نیمه‌ی «با کلید» داستان متفاوتی را می‌گوید و توضیح می‌دهد چرا انتقال کامل همچنان 158 اپیزود از آموزش از صفر جلو زد: در، محفظه و هدف تغییر نکرده‌اند و پانل $k=1$ یک مسیر آبی توپرِ کلید «در» هدف را حفظ می‌کند (46% حفظ کلی و نزدیک 100% در امتداد مسیر پایانی) است. انتقال روی این هدف هم‌زمان مضر (ناوبری بی‌کلید) و مفید (منطق پایان بازی) است؛ سود خالص و متوسط سرعت، برآیند این دو است.



شکل ۱۷: جاروب β روی هدف متفاوت

جاروب β ، شدت انتقال را جدا می‌کند. دو واقعیت روشن است: نخست، β جهش آغازین را تغییر نمی‌دهد؛ $\arg \max$ نسبت به مقیاس تغییرناپذیر است، پس هر $\beta > 0$ سیاست حریصانه‌ی اولیه‌ی یکسانی دارد (همان 3573- در داده‌ها)؛ β فقط از طریق دینامیک به‌روزرسانی اثر می‌گذارد، جایی که β کوچک‌تر یک پیشین ضعیف‌تر است که به‌روزرسانی‌های Temporal Difference سریع‌تر آن را بازنویسی می‌کنند. به همین دلیل β در اینجا نسبت به سرعت انطباق یکنوا است (622 / 478 / 500 اپیزود برای 0.25 / 0.75) و به همین دلیل $\beta = 0.25$ بهترین بازگشت نهایی را روی هدف مشابه به‌دست می‌آورد (190.2 در برابر 185.2 انتقال کامل؛ بزرگی‌های قدیمی‌تر با قدرت کامل ماندگارتر می‌شوند).

دوم، با بودجه‌ی 5000 اپیزودی، هر سناریو روی هدف متفاوت به مجانب جدولی یکسانی همگرا می‌شود (166--164 در برابر بهینه‌ی 179.8، و حدود 64 گام در برابر 50.2 گام بهینه؛ همان شکاف آشنای کف ε و α ثابت، نه یک اثر انتقال): انتقال تصمیم می‌گیرد که مجانب چقدر سریع به‌دست آید (تا 44% کاهش اپیزود)، نه این که کجا قرار بگیرد.

۳.۷ یک مورد انتقال منفی، از آغاز تا پایان

حالت (12,12)، $k = 0$ فاز 0: دو خانه دورتر از کلید قدیمی و درست پشت خانه‌ی جریمه‌ی (12,11). از فایل transfer_negative_case.csv (اجرای انتقال کامل روی هدف متفاوت، همراه با عکس‌های لحظه‌ای $Q(s)$ در حین آموزش):

جدول ۹: تحول مقادیر Q در حالت (12,12) طی آموزش روی هدف متفاوت

اپیزود	Q (بالا)	Q (پایین)	Q (چپ)	Q (راست)	عمل حریصانه
0 (منتقل شده)	-3.34	-2.14	-1.14	-1.73	چپ
100	-3.10	-1.20	+13.46	-1.73	چپ
500	-3.52	-2.99	-4.04	-2.93	راست
2500	-3.92	-4.03	-4.90	-3.92	بالا (تساوی قبلی)
بهینه‌ی هدف (Q^*)	32.68	27.49	20.36	34.63	راست

این جدول از چهار مورد قابل بررسی است:

۱. عمل حریصانه‌ی منتقل شده به چپ، به درون خانه‌ی جریمه، و به‌سوی کلیدی که دیگر وجود ندارد می‌رود، عمل بهینه‌ی هدف «راست» است، با فاصله‌ی عملی 14.3.

۲. تا اپیزود 100 خطا بزرگ تر شده است: راه اندازی از مقادیر همسایه ای که هنوز خوش بینی انتقال را دارند، به طور موقت q_{left} را تا $+13.5$ تقویت می کند، انتقال منفی می تواند پیش از تصحیح شدن، انباشته شود.


۳. تا اپیزود 500 واقعیت آن را در نظر نگرفته است: q_{left} فرو می ریزد و عمل حریصانه به «راست» بهینه ی هدف برمی گردد.

۴. از آن پس، سیاست در حال همگرایی دیگر اصلاً این حالت را بازدید نمی کند و مقادیرش در یک تساوی تقریبی کهنه سطح می شوند.

تصحیح دقیقاً زمانی رخ می دهد که حالت هنوز اهمیت دارد و پس از آن حالت رها می شود. نقشه ی ΔQ بخش ۲.۷ این کمان را مکانی جای گذاری می کند: (12,12) درون همان حوضه ی تاریک بازنویسی در $k = 0$ قرار دارد که مرکزش کلید حذف شده است.

۸ رابط گرافیکی MazeMario

دستور `python main.py` یک نمایش تصویری به سبک بازی‌های رترو با Tkinter اجرا می‌کند (پوشه‌ی `gui/`، شش ماژول؛ بدون Thread؛ یک لوپ `after()` گام‌های محیط، انیمیشن‌ها و نوار اطلاعات را پیش می‌برد). هر عنصر موردی را نشان می‌دهد: دیوارهای آجری، چاله‌های خارداری که قهرمان درون آن‌ها می‌افتد (همراه با 10- قرمزی که بالا می‌رود)، کلیدی درخشان و بالا-پایین‌رونده، دری چوبی که کنار می‌رود، و شاهزاده‌ای در هدف و دروازه‌ی دوره‌ای یک اژدهاست که در فازهای بسته از لانه‌اش بیرون می‌آید و در فازهای باز عقب می‌نشیند، همراه با شمارش معکوس در نوار اطلاعات (`OUT n / IN n`)، که ویژگی پویای انتخاب‌شده را به برجسته‌ترین شیء بصری بازی تبدیل می‌کند.



شکل ۱۸: صفحه‌ی عنوان و منوی MazeMario

صفحه‌ی عنوان/مکث، دو کنترل نخست خواسته‌شده را به شکل منوی بازی ارائه می‌کند: انتخاب جهان (مبدأ و هر دو هدف انتقال)، انتخاب مغز عامل، و کلید تغییر حالت. دو تصمیم طراحی دیده می‌شود: گزینه‌ی `VALUE ITERATION` با برچسب `WATCH` ONLY مشخص شده و سطر `TRAIN` هنگام انتخاب آن خاکستری می‌شود، `Value Iteration` دقیقاً از روی مدل برنامه‌ریزی می‌شود، پس چیزی برای تماشای آموزش وجود ندارد (بخش ۱۰، Q3) و هر انتخابگر به جای بازسازی منو، در جای خود ویرایش می‌شود

تا جابه‌جایی میان گزینه‌ها بدون پرش تصویر باشد.

جدول ۱۰: تناظر کنترل‌های خواسته‌شده با عناصر رابط گرافیکی

کنترل خواسته‌شده	عنصر رابط گرافیکی
انتخاب الگوریتم و محیط مبدأ/هدف	منوهای HERO BRAIN و SELECT WORLD
حالت آموزش در برابر ارزیابی	MODE: TRAIN / WATCH
شروع / توقف / ادامه / بازنشانی / اجرای دوباره	RESTART, PLAY/PAUSE, START (به‌علاوه‌ی گام‌به‌گام STEP)
سرعت انیمیشن	لغزنده‌ی سرعت از 0.5 تا 4 برابر (از 2 برابر به بالا آموزش را جلو می‌برد، حدود 60 اپیزود بر ثانیه)
کلید نمایش سیاست	پوشش POLICY - پیکان‌های حریصانه برای وضعیت کلید و فاز دروازه‌ی کنونی عامل، که در حین آموزش زنده به‌روز می‌شوند
اطلاعات زنده: اپیزود، گام، پاداش، ϵ ، کلید، نرخ موفقیت اخیر	نوار اطلاعات: EP, n/cap, STEPS, SCORE, ϵ , KEY, WIN (100 اپیزود اخیر)



شکل ۱۹: اجرای بازی همراه با پوشش نمایش سیاست

نمای میانه‌ی اپیزود در حالت WATCH (Value Iteration، جهان ۱) با پوشش POLICY روشن. پیکان‌ها همان سیاست بهینه‌ی بخش ۳ هستند که به صورت زنده برای وضعیت کلید و فاز دروازه‌ی کنونی قهرمان رسم می‌شوند و با پیشروی چرخه‌ی اژدها آشکارا سازمان‌دهی مجدد می‌شوند، که همان وابستگی به فاز شبکه‌ی سیاست بخش ۳ است که تعاملی شده. لحظه‌ی ثبت شده نشان می‌دهد ویژگی کار می‌کند: نوار اطلاعات 1 DRAGON OUT را نشان می‌دهد و اژدها در درگاه، پیش از در ایستاده است؛ دقیقاً همان مسیر مسدودی که تحلیل زمان‌بندی درباره‌ی آن است. کلید، چاله‌ی خاردار و شاهزاده هر یک از نظر بصری متمایزند، همان‌طور که مشخصات می‌خواهد، و نوار اطلاعات امتیاز (22- پس از 17 گام 1- به علاوه‌ی یک لغزش به دیوار) و سقف گام را زنده دنبال می‌کند.



شکل ۲۰: صفحه‌ی پیروزی MazeMario

پایان اپیزودها مشخص است: رسیدن به شاهزاده بئر COURSE CLEAR را بالا می‌آورد (و نسخه‌ی TIME UP قطع شدن به دلیل سقف گام را پوشش می‌دهد). اعداد میان دو نمایش با هم می‌خوانند - SCORE 204 و 39 STEPS روی پوشش، همان وضعیت نهایی نوار اطلاعات است، همراه با KEY GOT! و WIN 100% - چون هر دو یک وضعیت اپیزود را می‌خوانند؛ این اجرای خاص با گرفتن لغزش‌های مساعد، از میانگین ارزیابی 43.4 گامی بخش ۳ بهتر عمل کرده است.

حالت WATCH سیاست‌های آموزش دیده را بازپخش می‌کند (Value Iteration برای جهان انتخابی زنده حل می‌شود؛ جدول‌های Q-Learning و SARSA از results/models/ بارگذاری می‌شوند)؛ حالت TRAIN یک یادگیرنده‌ی تازه را با زمان‌بندی ϵ پیکربندی اجرا می‌کند و در بودجه‌ی 5000 اپیزودی متوقف می‌شود (ϵ عبارت DONE را نشان می‌دهد)، و پس از آن قهرمان جدول

آموخته‌ی خود را حریصانه بازی می‌کند. انتخاب جدول Q آموزش دیده روی مبدأ در جهان متفاوت، انتقال منفی بخش ۳.۷ را زنده نشان می‌دهد: قهرمان به‌سوی کلید حذف شده رژه می‌رود. یک جلسه‌ی TRAIN مشاهده شده در رابط گرافیکی (نرخ برد 56% حوالی اپیزود 880 و 89% تا حدود 1100) با منحنی‌های یادگیری بدون رابط بخش ۴ همخوان است؛ بازی، همان محیط و همان قواعد به‌روزرسانی است، فقط متحرک شده.

۹ جمع‌بندی مقایسه

جدول ۱۱: جمع‌بندی کیفی و کمی سه الگوریتم

معیار	Value Iteration	Q-Learning	SARSA با $\lambda = 0.7$
نیازمندی	مدل کامل P و R	فقط تعامل با محیط	فقط تعامل با محیط
واحد پیشرفت	جاروب بلمن	اپیزود	اپیزود
خروجی	π^*, V^*	π, Q	π, E, Q
محاسبه برای این مسئله	حدود 0.1 ثانیه	حدود 8 ثانیه	حدود 54 ثانیه
نمونه برای این مسئله	0	حدود 850 هزار گام	حدود 770 هزار گام
بهینگی حاصل شده	دقیق (اثبات با انقباض)	حدود 95--99% از V^* ؛ مجانِب توسط کف ϵ و α ثابت تعیین می‌شود	همان رده، اما اینجا اندکی بهتر (V^π برابر 7.83 در برابر (5.93)
رفتار نزدیک خطر	بهینه‌ی خنثی نسبت به ریسک	تخمین‌های خنثی نسبت به ریسک	مسیرهای به‌طور قابل اندازه‌گیری ایمن‌تر (On-Policy)
حساسیت بررسی شده	γ (بخش ۳)	زمان‌بندی ϵ و شکل‌دهی پاداش (بخش ۴)	λ (بخش ۵)

۱۰ پاسخ به پرسش‌های تحلیلی

پرسش ۱ - مسئله را به‌عنوان یک MDP کامل تعریف کنید؛ حالت چگونه خاصیت مارکوف را حفظ می‌کند؟

بخش ۲.۲ مجموعه‌ی S, A, P, R, γ ، حالت‌های پایانی و سیاست را ارائه می‌دهد. حالت $(r, c, \text{has_key}, \text{gate_phase})$ هر متغیری را که بر آینده اثر می‌گذارد در بر دارد: عبورپذیری در از has_key و عبورپذیری دروازه از gate_phase نتیجه می‌شود، پس $P(s' | s, a)$ به هیچ تاریخچه‌ای نیاز ندارد. حذف فاز باعث می‌شود همان (x, y, k) بسته به زمان رسیدن رفتار متفاوتی نشان دهد؛ همان نقض عینی خاصیت مارکوف که انتخاب ویژگی ما برای آشکار کردنش طراحی شده بود.

پرسش ۲ - رفتار On-Policy در برابر Off-Policy نزدیک خانه‌های خطرناک

هدفِ بیشینه‌گیر Off-Policy در Q-Learning مقادیر سیاست **حریصانه** را می‌آموزد در حالی که رفتارش اکتشافی است؛ اما هدف SARSA On-Policy لغزش‌های ϵ -greedy خودش را در Q قیمت‌گذاری می‌کند. پیامد اندازه‌گیری‌شده (بخش ۶): SARSA در ارزیابی حریصانه کمترین ورود به خانه‌های جریمه را دارد (0.188 در هر اپیزود در برابر 0.236 برای Q-Learning و 0.260 برای Value Iteration) و انحراف‌هایش از Value Iteration در مجاورت جریمه **واضح** است (توافق 63.7% در برابر 67.3% برای Q-Learning، که هر دو بسیار بالاتر از توافق سراسری حدوداً 51% آن‌هاست؛ یعنی شکاف‌ها نزدیک خطر تیزند، نه تصادفی). حالت نمونه‌ی ۱ در بخش ۶ نمایش عینی آن است: SARSA انحرافی را ترجیح می‌دهد که در Q^* به‌اندازه‌ی 3.13- می‌ارزد، چون ریسک لغزش را از یک چاله دور نگه می‌دارد.

پرسش ۳ - چرا Value Iteration به مدل انتقال نیاز دارد و دو روش دیگر بدون آن یاد می‌گیرند؟

پس‌انتشار Value Iteration به‌صراحت روی $P(s' | s, a)$ میانگین می‌گیرد؛ این روش **خودش** محاسبه‌ای روی مدل است (که اینجا دقیقاً به‌وسیله‌ی $()$ transitions افشا شده است، بخش ۲.۲). روش‌های Temporal Difference، آن امید ریاضی را با انتقال‌های نمونه‌گیری‌شده جایگزین می‌کنند: هر پیامد $\text{step}()$ یک نمونه‌ی نارایب از همان توزیع است. مبادله‌ی اندازه‌گیری‌شده در این پروژه: با مدل، بهینگی دقیق در حدود 0.1 ثانیه و صفر نمونه؛ بدون مدل، حدود 500 تا 600 هزار گام محیط تا رسیدن به حوالی بهینه (بخش ۶).

- **مزیت بدون مدل:** وقتی مدل در دسترس یا قابل‌نوشتن نیست کار می‌کند.
- **محدودیت بدون مدل:** هزینه‌ی نمونه و زیربهینگی باقی‌مانده، که در جاهایی متمرکز است که تجربه کمیاب بوده.
- **مزیت مبتنی بر مدل:** دقت و سرعت.
- **محدودیت مبتنی بر مدل:** دقیقاً به همان چیزی نیاز دارد که مسائل واقعی به‌ندرت در اختیار می‌گذارند (و مدل دقیق ما همان چیزی بود که Value Iteration را به حقیقت مبنا برای نمره‌دهی به دو روش دیگر تبدیل کرد).

پرسش ۴ - کدام λ بهترین توازن میان سرعت و پایداری یادگیری را می‌دهد؟

مقدار $\lambda = 0.7$ (بخش ۱.۵): 982 اپیزود تا موفقیت پایدار (در برابر 1670 برای $\lambda = 0$ و 805 برای $\lambda = 0.9$)، کمترین و یکنواخت‌ترین واریانس اواخر آموزش (انحراف معیار بازگشت 16.5--24.4 در برابر 72 برای $\lambda = 0$ و 31.6 برای $\lambda = 0.9$) و بهترین بازگشت‌های نهایی (189.5--190.8). مقدار $\lambda = 0.9$ سریع‌تر به نشان 90% می‌رسد اما در همگرایی نویزی‌تر است، چون ردهای بلند دلتای لغزش‌های اکتشافی را به عقب منتشر می‌کنند.

پرسش ۵ - سه حالت که سیاست بدون مدل با Value Iteration تفاوت دارد، همراه با تحلیل موضعی

بخش ۶: خانه‌ی (2,1) - یک انحراف ایمنی On-Policy نظام‌مند در کنار یک چاله (فاصله‌ی 3.13، 669 بازدید)؛ خانه‌ی (15,15) - یک تساوی دقیق میان دو مسیر متقارن به هدف (فاصله‌ی 0.000، 1418 بازدید)؛ و خانه‌ی (14,12) - یک خطای واقعی روی خود خانه‌ی دروازه (فاصله‌ی 19.7) که بر اثر کمبود داده باقی مانده است (5 بازدید). این سه با هم نشان می‌دهند که اختلاف سه علت متفاوت دارد - شکل‌دهی ریسک، تساوی‌شکنی و نبود داده - و تنها سومی یک نقص واقعی است.

پرسش ۶ - هدف مشابه در برابر هدف متفاوت در انتقال

بخش ۲.۷: روی هدف مشابه، جدول‌های منتقل‌شده با موفقیت 100% جهش آغازین دارند و تعداد اپیزود تا 90% را حدود 7 برابر کاهش می‌دهند (99 در برابر 718). روی هدف متفاوت، جهش آغازین 0% است (سیاست به‌سوی کلید حذف‌شده می‌رود)، سرعت یادگیری همچنان بهبود می‌یابد (691 در برابر 849 برای انتقال کامل و 478 در $\beta = 0.5$ ، یعنی 44% کاهش)، و انتقال منفی ظاهر می‌شود؛ که در بخش ۳.۷ با عکس‌های لحظه‌ای Q در طول ظهور، تصحیح و رهاشدن به‌طور عینی بازسازی شده است. با بودجه‌ی همگراشده، عملکرد نهایی مستقل از سناریو است (همان مجانب جدولی)؛ انتقال تنها سرعت رسیدن به آن را جابه‌جا می‌کند. مقدار β هرگز سیاست حریصانه‌ی اولیه را تغییر نمی‌دهد (تغییرناپذیری $\arg \max$ نسبت به مقیاس)، β فقط تنظیم می‌کند که پیشین با چه شدتی در برابر تصحیح مقاومت کند، که روی هدف مشابه سودمند است ($\beta = 0.25$) با بازگشت نهایی (190.2) و روی هدف متفاوت باید معتدل باشد ($\beta = 0.5$ سریع‌ترین است).

۱۱ بازتولیدپذیری

همه‌ی نقشه‌ها، مدل‌ها، فایل‌های CSV و شکل‌ها از کد و پیکربندی ثبت‌شده بازتولید می‌شوند؛ به بخش بازتولید نتایج در README رجوع کنید. مجموعه‌ی نهایی خروجی‌ها در این مخزن با حذف کامل پوشه‌ی results/ و اجرای دوباره‌ی خط لوله تولید شده است؛ تولید نقشه و تمام اجراهای آموزش بذردهی‌شده‌اند (بذرهای آموزش {7, 21, 42} و بذر ارزیابی 999) و خروجی‌های بازتولیدشده‌ی Value Iteration, Q-Learning, SARSA و مقایسه، سطر به سطر با اجرای پیشین مطابقت داشتند (به جز میدان‌های زمان اجرا که تابع بار ماشین‌اند). آزمون‌های واحد با `python -m pytest tests/` اجرا می‌شوند (60 آزمون). تصاویر رابط گرافیکی در بخش ۸ عکس‌های زنده‌ی برنامه هستند و تنها خروجی بصری‌اند که خط لوله‌ی آزمایش آن‌ها را تولید نکرده است.

۱۲ پیاده‌سازی‌های فیچرهای دیگر

این هزارتو در چهار پیاده‌سازی کامل وجود دارد، یکی به‌ازای هر شاخه، که هر کدام اجرای کامل دوباره‌ی خط لوله‌ی یکسان روی نقشه‌های بایت‌به‌بایت یکسان‌اند، و گزارش هر پیاده‌سازی با یک بازنگری نسبت به همین خط پایه بسته می‌شود:

جدول ۱۲: چهار شاخه‌ی پیاده‌سازی و نتیجه‌ی شاخص هر یک

شاخه	ویژگی پویا	نتیجه‌ی شاخص
main (همین شاخه)	دروازه‌ی دوره‌ای با معنانشناسی هنگام خروج	خط پایه‌ی متعارف: هر یادگیرنده به‌راحتی همگرا می‌شود (Q-Learning حدود 1,099 و SARSA(0.7) حدود 982 اپیزود تا 90%)
future_phase	همان دروازه، اما باز هنگام رسیدن	یک تغییر تک‌محمولی، مسئله را بدون هیچ هزینه‌ای عمیق‌تر می‌کند: قاعده‌ی ساده‌لوحانه‌ی «گر باز به‌نظر می‌رسد وارد شو» در 2 فاز از 6 فاز به‌طور اثبات‌پذیر زیربهبینه می‌شود و بازی بی‌نقص باید حدود 3 گام برای زمان‌بندی کنار بگذارد
wizard_obstacle	مانع متحرک - جادوگری که در یک گشت‌زنی 4 خانه‌ای در درگاه جابه‌جا می‌شود	هم‌ارزی اندازه‌گیری‌شده با دروازه (V^*)، تعداد جاروب‌ها و سرعت یادگیرنده‌ها همگی در محدوده‌ی نویز - و لبه‌ی تیز آن: هم‌ارزی تنها وقتی برقرار است که طولانی‌ترین توقف پیوسته‌ی مانع با بازه‌ی بسته‌ی دروازه برابر باشد. استواری میان‌طرح که خواص روش را از تصادف‌های دینامیک جدا می‌کند نیز اینجاست
limited_energy	بودجه‌ی انرژی قابل مشاهده (حالت $\times 17$)	Q-Learning تک‌گامی اسپارس از نظر تعداد اپیزود 28.5 برابر مقیاس می‌گیرد، در حالی که ردها 11.5 برابر و شکل‌دهی 14.8 برابر؛ یک باند وارونه‌ی «استیصال» (احتیاط هنگام فقر)؛ یک تله‌ی انتقال منفی دائمی که تنها انتقال گزینشی از آن جان به‌در می‌برد؛ و یک منحنی عملیاتی اندازه‌گیری‌شده برای E_0

دروازه در این شاخه، تمیزترین نماینده کمینه از ساختار مارکوف زمانی و امن‌ترین مجموعه‌ی خروجی برای بازتولید باقی می‌ماند؛ عمیق‌ترین تحلیل از میان این چهار روی limited_energy است، و قوی‌ترین شواهد روش‌شناختی، این‌که کدام یافته‌ها در همه‌ی دینامیک‌ها تکرار می‌شوند و کدام‌ها برعکس، در بازنگری wizard_obstacle قرار دارد. برای مطالعه‌ی متعارف، این گزارش را بخوانید و سپس آن دو را برای دیدن شکل فضای طراحی پیرامون آن بررسی کنید.